흉부 X-ray 폐렴 분류 최종 보고서

AI 헬스케어 해커톤 · 김지연 · OZ코딩스쿨 AI 헬스케어 7기 · 2026.09.22 ~ 10.18

한눈에 보기

0.7804 → 0.9583
제출 점수 (Baseline → 최종)
624장 중 487장 → 598장

16.2%p → 1.4%p
검증 정확도와 제출 점수의 차이

0.457 → 0.952
가로로 긴 정상 사진의 정확도
(검은 띠 단서를 쓰는지 보는 지표)

- **과제:** 소아 흉부 X-ray를 정상(0) / 폐렴(1)으로 분류함. 평가는 test 624장의 정확도임
- **핵심 발견:** train 사진에만 있는 **위아래 검은 띠의 두께**가 정답과 강하게 연결돼 있었음. 모델은 폐가 아니라 띠를 보고 맞히고 있었고, 그래서 검증은 높은데 제출 점수는 낮았음
- **해결:** 검은 띠를 잘라내고 사진 비율을 무작위로 흔들어 학습함. 모델 하나로 0.9471, 같은 전처리의 모델 셋을 평균내 0.9583이 됨
- **최종 모델:** ImageNet 사전학습 EfficientNet-B0 + ResNet50 + DenseNet121, 환자 묶음 5-fold, 세 모델 확률 평균, 판정 기준 0.5
- **지킨 원칙:** test 데이터는 예측에만 씀. 학습, 통계 계산, 판정 기준 결정에는 한 번도 쓰지 않음

① 맞추기	② 의심하기	③ 쌓기	④ 원인 찾기	⑤ 다듬기
test도 train처럼 letterbox, 사전학습 모델 0.7804 → 0.8526	검증 0.99인데 제출 0.85 → 환자 누수 발견, 묶음 분할 → 0.8686	모델·앙상블을 바꿔 가며 버팀 (원인은 모름) → 0.92	검은 띠 두께가 정답을 알려줌 → 띠 제거 → 0.9471	같은 전처리로 모델을 더해 평균 → 0.9583

그림 1. 문제를 푼 순서. ③까지는 점수를 올렸지만 이유를 설명하지 못했고, ④에서 원인을 찾은 뒤 처음으로 검증과 제출이 같은 방향을 가리킴

1 문제 정의와 원칙

항목	내용
입력 / 출력	흉부 X-ray 사진 한 장 → 정상(0) 또는 폐렴(1)
데이터	train 5,216장 (정상 1,341 / 폐렴 3,875, 약 1:3), test 624장 (정답 없음)
평가	test 624장의 정확도 (Accuracy). 하루 10회까지 제출 가능
규칙	test 데이터를 학습이나 통계 계산(인코딩, 스케일링, 결측치 처리 등)에 쓰면 Data leakage

시작하면서 스스로 정한 원칙은 세 가지임.

1. **test는 예측에만 쓴다.** pseudo-label, test 통계로 정규화하기(AdaBN) 같은 방법은 점수를 올릴 수 있어도 쓰지 않음
2. **판정 기준은 0.5로 둔다.** 제출 점수를 보며 기준이나 폐렴 판정 비율을 맞추지 않음
3. **무엇을 고를지는 검증으로 정한다.** 리더보드는 결과 확인용이고, 실험 하나는 한 번만 제출함

처음에는 "좋은 모델을 고르는 문제"라고 생각했음. 실제로는 train과 test의 사진 형태가 다르다는 것이 핵심이었고, 점수를 크게 바꾼 것은 모델이 아니라 입력이었음.

2 데이터에서 찾은 세 가지

2.1 train과 test의 사진 형태가 다름

- **train:** 전부 224×224. 원본 비율을 유지한 채 넣고 남는 곳을 검게 채운 형태(letterbox)이고, 일부는 회전·확대돼 있음
- **test:** 원본 크기 그대로임 (1936×1554, 1612×941 등 제각각)
- **대응:** test도 같은 letterbox로 맞춤. 그냥 224×224로 늘리면 사진이 찌그러져 학습 때와 다른 그림이 됨



그림 2. test 사진의 전처리. 원본 → letterbox(train과 같은 모양) → 검은 띠 제거(최종 모델 입력)

2.2 무작위로 나누면 검증 점수가 부풀려짐

- 파일 번호가 환자 순서대로 되어 있어서 옆 번호끼리는 같은 환자의 사진인 경우가 많음
- 사진을 한 장씩 무작위로 나누면 검증 사진의 **94%**가 바로 옆 번호 사진을 학습에 둠. 그 상태의 검증 정확도는 0.9875였지만 제출 점수는 0.8526이었음
- 환자 ID가 없어서 **연속된 10장을 한 환자 묶음**으로 보고, 묶음이 쪼개지지 않게 5-fold로 나눔 (StratifiedGroupKFold). 이후 모든 검증은 이 방식임

2.3 검은 띠의 두께가 정답을 알려줌 (가장 중요한 발견)

검은 띠를 뺀 내용 부분의 가로 ÷ 세로 비율을 라벨별로 비교했음.

	내용 부분 가로÷세로 (중앙값)	letterbox 후 모습
정상	1.18	위아래 검은 띠가 얇음
폐렴	1.44	위아래 검은 띠가 두꺼움

- 폐를 전혀 보지 않고 **이 비율 하나만으로 AUC 0.88**이 나옴. 비율이 1.5를 넘는 train 사진은 99.5%가 폐렴임
- 그런데 test에는 가로로 긴 정상 사진이 많음. 띠를 보고 배운 모델은 test에서 이런 정상을 폐렴으로 판정함
- 그동안의 오답(정상을 폐렴으로 과신)과 정확히 맞아떨어졌음

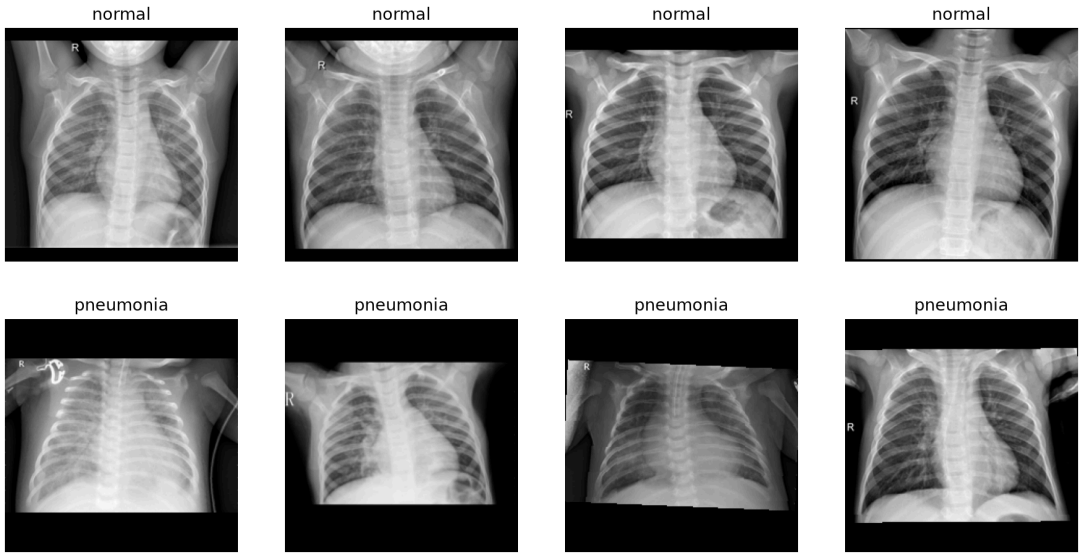


그림 3. train 사진 예시. 윗줄 정상, 아랫줄 폐렴. 폐렴 사진의 위아래 검은 띠가 더 두꺼움

3 해결 전략

문제	전략	이유
train·test 형태 차이	test도 letterbox로 맞춘 뒤 같은 전처리	학습 때와 같은 그림을 보게 함
환자 누수	10장 묶음 단위 5-fold	검증 점수를 믿을 수 있게 함
검은 띠 단서	검은 띠를 잘라내고 224×224에 꽉 채움	띠의 두께 정보를 없앰
비율 단서	학습 때 가로세로 비율을 무작위로 흔듦 (0.75~1.33)	띠를 없애도 남는 "늘어난 정도"로 맞히지 못하게 함
클래스 불균형	클래스 가중치 (정상 약 1.94, 폐렴 0.67)	적은 쪽(정상)을 틀리면 더 큰 벌점
데이터가 적음	ImageNet 사전학습 모델, 전체 층 미세조정	5천 장으로 처음부터 학습하기 어려움
모델 하나의 흔들림	5-fold 평균 + 구조가 다른 모델 3개 평균	에포크마다 검증 정확도가 0.92~0.98로 크게 흔들림

외부 사전학습 모델 사용에 대한 판단
실험 중에 흉부 X-ray로 사전학습된 공개 모델(torchxrayvision의 DenseNet121, 폐 분할 PSPNet)을 썼음. ImageNet 사전학습 모델과 같은 "공개 사전학습 가중치"로 보고 사용했고, 폐 분할 모델은 폐 위치만 찾는 데 썼음. 폐렴 라벨이 있는 외부 데이터는 쓰지 않았고, 분류 모델 학습에는 대회 데이터만 사용함. 최종 모델은 ImageNet 사전학습 모델만 씀

4 실험 과정

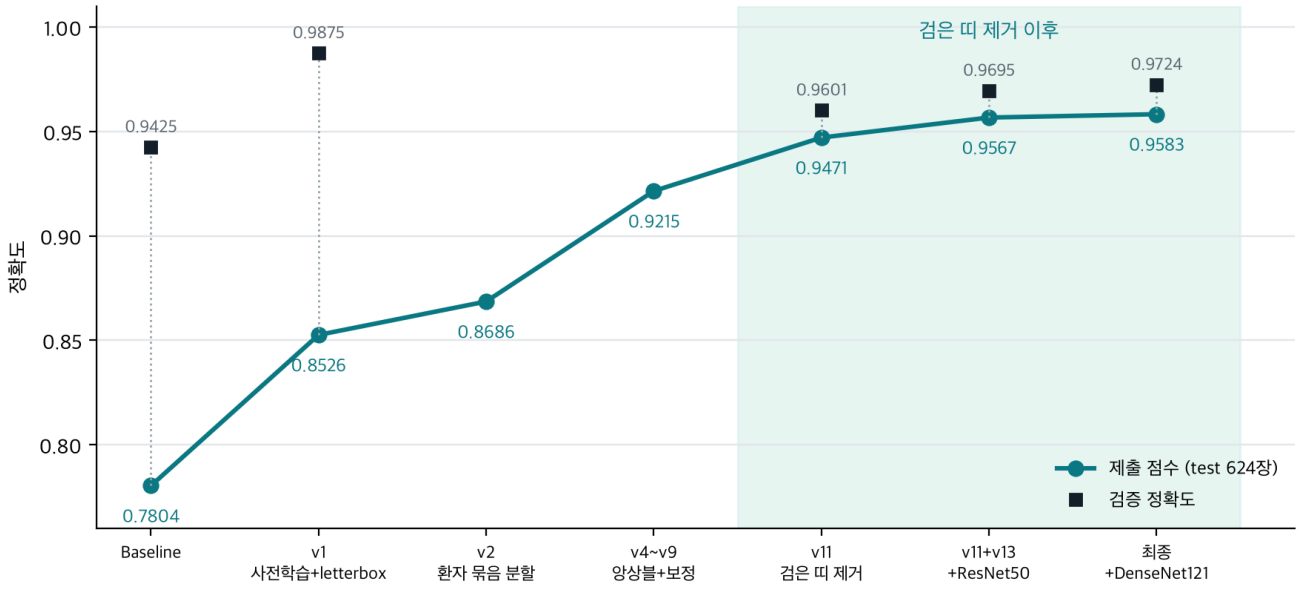


그림 4. 단계별 제출 점수(선)와 검증 정확도(네모). 검은 띠를 제거한 뒤로 두 값의 차이가 1%p대로 줄어듦. v1의 검증은 무작위 분할, 나머지는 환자 묶음 5-fold임

4.1 맞추기: test 형태 통일과 사전학습 모델 (v1)

대회 Baseline(SimpleCNN, 128×128 흑백, 2 에포크)의 구조를 유지하면서 test에도 letterbox를 적용하고, ImageNet 사전학습 EfficientNet-B0으로 바꿈. 클래스 가중치, 증강, 10 에포크를 더했음. 제출 점수는 0.7804에서 0.8526으로 올랐음.

그런데 검증 정확도는 0.9875였음. 13%p 넘는 차이를 과적합으로 볼지 다른 원인으로 볼지가 다음 질문이 됐음.

4.2 의심하기: 환자 누수와 묶음 분할 (v2, v4)

파일 번호 순서를 보다가 옆 번호가 같은 환자라는 것을 알았고(2.2절), 10장 묶음 분할로 바꿈(v2, 0.8686). v4부터는 묶음 단위 5-fold로 모델 5개를 학습해 평균냈음. 검증이 정직해졌는데도 제출은 0.90 근처에 머물렀음.

4.3 쌓기: 원인을 모른 채 앙상블 (v5~v9)

- 흉부 X-ray 사전학습 모델(v5), ConvNeXt(v7), 폐 영역만 잘라 학습(v8·v9)을 차례로 앙상블해 0.9215까지 올림
- 이 시기에는 판정 기준(0.99)이나 폐렴 판정 비율(약 58%)을 리더보드를 보며 정했음. **test 예측 분포에 의존하는 보정**이라 일반화된 선택이 아니었고, 최종 모델에서는 쓰지 않음
- 앙상블은 모델 수보다 **예측끼리의 상관**이 중요했음. 비슷한 X-ray 모델을 더 넣었을 때(v6, 상관 0.92~0.95)는 오히려 내려갔음

4.4 원인 찾기: 검은 띠 제거 (v10, v11)

전처리를 다시 점검하다가 검은 띠의 두께가 정답과 연결돼 있다는 것을 찾았음(2.3절). 띠를 잘라내고 비율 흔들기를 넣자, 검증 전체 정확도는 오히려 내려갔지만 **단서와 정답이 어긋나는 사진**에서는 올라갔음.

교차검증 결과	전체	가로로 긴 정상 (105장)	정사각에 가까운 폐렴 (393장)
v4 (검은 띠 그대로)	0.9862	0.9048	0.9593
v10 (띠 제거, 6 에포크)	0.9528	0.9619	0.8830

v10은 폐렴을 많이 놓쳐서(226장) 과소적합으로 보고 에포크만 6 → 10으로 늘림(v11). **모델 하나, 기준 0.5, 보정 없이 0.9471**이 나왔고, 모델 넷을 섞고 비율까지 맞춘 이전 최고(0.9215)보다 높았음. 띠를 배운 예전 모델과 섞으면 다시 내려갔음 → 앙상블이 아니라 전처리가 답이었음.

4.5 다듬기: 같은 전처리로 모델 더하기 (v12, v13, 최종)

띠를 제거한 전처리를 그대로 두고 구조가 다른 모델을 하나씩 더해 확률을 평균냈음. 모델마다 틀리는 방향이 달랐음 (EfficientNet-B0은 폐렴을 많이 놓치고, ResNet50은 정상을 폐렴으로 많이 봄).

모델	검증 정확도	정상→폐렴	폐렴→정상	제출 점수
EfficientNet-B0 (v11)	0.9601	17	191	0.9471
+ X-ray 사전학습 DenseNet (v12)	0.9586	17	199	0.9487
+ ResNet50 (v11+v13)	0.9695	18	141	0.9567
+ DenseNet121 (최종, 세 모델)	**0.9724**	**18**	**126**	**0.9583**

624장 중 591 → 597 → 598장으로, 뒤로 갈수록 얻는 것이 작아졌음. 세 모델의 순위 상관은 0.80~0.88임.

4.6 실험 관리

- **한 번에 하나만 바꿈:** 바꾼 것이 여럿이면 무엇 때문에 변했는지 알 수 없음
- **재개 가능한 학습:** fold가 끝날 때마다 결과를 파일로 저장해, 중간에 멈춰도 끝난 fold는 건너뜀
- **코드 관리:** `.py` 로 쓰고 노트북으로 변환함. 버전끼리 비교하기 쉬움
- **제출 규칙:** 실험 하나는 한 번만 제출하고, 최종 선택은 오를 때만 바꿈

5 실험 비교

5.1 전체 제출 기록

버전	바꾼 것	검증	제출 점수
Baseline	대회 기본 SimpleCNN	0.9425	0.7804
v1	EfficientNet-B0, letterbox 통일, 클래스 가중치, 증강	0.9875*	0.8526
v2	환자 묶음 분할, label smoothing	-	0.8686
v4	EfficientNet-B0 5-fold (기준 0.99)†	0.9862	0.9022
v4~v9	X-ray 사전학습·ConvNeXt·폐 자르기 앙상블 (비율 보정)†	-	0.9119~0.9215
v11	**검은 띠 제거 + 비율 흔들기**, 10 에포크	0.9601	0.9471
v11+v12	+ X-ray 사전학습 DenseNet	0.9586	0.9487
v11+v12	판정 기준 0.3	0.9716	0.9439
v11+v13	+ ResNet50	0.9695	0.9567
v11+v13+v14	ResNet50을 시드만 바꿔 하나 더	0.9689	0.9567
v11+v13+v15	+ 폐 영역 자르기 ResNet50	0.9770	0.9487
최종	**v11 + v13 + DenseNet121 (세 모델 평균)**	**0.9724**	**0.9583**

* 무작위 분할 검증(환자 누수 있음). 나머지 검증은 환자 묶음 5-fold. † 리더보드를 보며 정한 판정 기준·비율 보정이 들어간 제출로, 최종 모델에서는 쓰지 않은 방식임

5.2 단계별로 얼마나 올랐나

단계	제출 점수	변화
Baseline	0.7804	
test 형태 통일 + 사전학습 모델 (v1)	0.8526	+7.2%p
환자 묶음 분할 (v2)	0.8686	+1.6%p
검은 띠 제거 + 비율 흔들기 (v11)	0.9471	**+7.9%p**
+ ResNet50	0.9567	+1.0%p
+ DenseNet121	0.9583	+0.2%p

크게 오른 두 단계(+7.2%p, +7.9%p)는 둘 다 **모델이 아니라 입력을 바꾼 것**임. 모델을 더한 효과는 합쳐서 +1.2%p였음. 비율 보정이 섞인 v4~v9는 기여 계산에서 뺐음.

5.3 검증과 제출의 차이

시점	검증	제출	차이
Baseline	0.9425	0.7804	16.2%p
v1 (무작위 분할)	0.9875	0.8526	13.5%p
v11 (검은 띠 제거)	0.9601	0.9471	1.3%p
최종	0.9724	0.9583	1.4%p

교란 특징을 없앨수록 검증 점수가 실제 성능에 가까워졌음. 다만 1%p대에서도 **방향**은 맞지 않았음(6장).

6 효과가 없었던 시도

시도	기대한 근거	제출 결과
판정 기준 0.5 → 0.3	검증에서 폐렴을 많이 놓쳤고, 검증상 0.3이 더 높았음(0.9586 → 0.9716)	0.9487 → 0.9439
흉부 X-ray 사전학습 모델	의료 영상으로 배운 모델이 나을 것	평균해도 +1장
폐 영역만 잘라 학습한 ResNet50 추가	폐만 보면 더 정확할 것. 검증 0.9695 → 0.9770	0.9567 → 0.9487
시드만 바꿔 다시 학습	평균하면 안정될 것	624장 예측 동일
띠 단서를 배운 예전 모델과 앙상블	모델이 많을수록 좋을 것	오히려 하락

검증이 오른 변경이 제출에서는 내려간 경우
기준 0.3과 폐 영역 자르기는 둘 다 검증 점수를 올렸지만 제출에서는 내려갔음. 두 변경 모두 test 판정을 **폐렴 쪽으로** 옮겼다는 공통점이 있음. 검증에서는 폐렴을 놓치는 것이 약점인데 test에서는 그렇지 않다는 뜻으로 보았음. 이 결과를 보고 기준을 반대로 조정하면 리더보드에 맞추는 것이 되므로, 기준은 0.5로 두었음

7 최종 모델과 성능 분석

7.1 최종 모델

항목	내용
전처리	letterbox(train과 같은 모양) → 검은 띠 제거 → 224×224, 흑백을 3채널로 복사, ImageNet 정규화
증강	비율 흔들기(75~100% 영역, 비율 0.75~1.33), 회전 ±10°, 이동 5%, 확대·축소 0.9~1.1, 밝기·대비 ±20%
모델	ImageNet 사전학습 EfficientNet-B0(10 에포크), ResNet50(8), DenseNet121(8), 전체 층 미세조정
학습	AdamW(1e-4, weight decay 1e-4), Cosine 학습률, 클래스 가중치, 배치 32
검증	10장 묶음 단위 5-fold. fold마다 검증 정확도가 가장 높은 에포크의 가중치 사용
예측	모델마다 5개 fold 평균(원본 + 좌우반전) → 세 모델 확률 평균 → 기준 0.5
성능	검증 0.9724, AUC 0.9971 · 제출 0.9583 (598 / 624장)

7.2 Before vs After

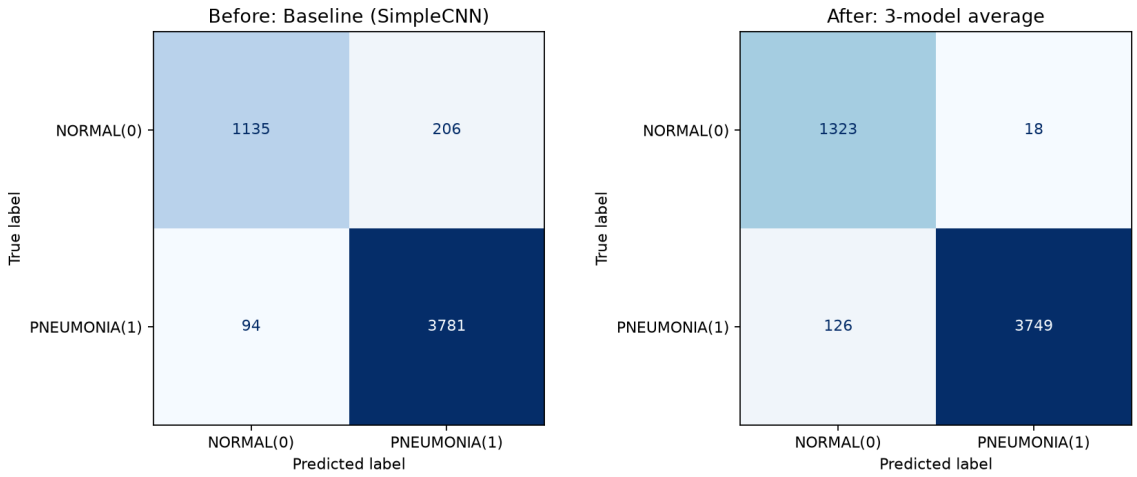


그림 5. 혼동행렬. 왼쪽 Baseline(SimpleCNN), 오른쪽 최종 모델. 같은 5-fold로 train 5,216장 전체를 검증한 결과임

	Baseline	최종 모델
검증 정확도 / AUC	0.9425 / 0.9819	0.9724 / 0.9971
민감도 (폐렴을 폐렴으로)	0.9757	0.9675
특이도 (정상을 정상으로)	0.8464	0.9866
FP / FN	206 / 94	18 / 126
가로로 긴 정상 사진 정확도	0.457	0.952
제출 점수	0.7804	0.9583

- 가장 크게 좋아진 것은 **특이도**임. 정상을 폐렴으로 본 사진이 206장에서 18장으로 줄었음

- Baseline은 검증 정확도가 0.94여도 가로로 긴 정상은 절반도 못 맞혔고, 제출 점수는 검증보다 16%p 낮았음. 지름길로 얻은 점수는 test에서 무너짐
- 대신 최종 모델은 **폐렴을 놓치는 쪽**으로 틀림(FN 126장). 민감도는 Baseline보다 조금 낮음

7.3 어떤 사진을 틀리는가

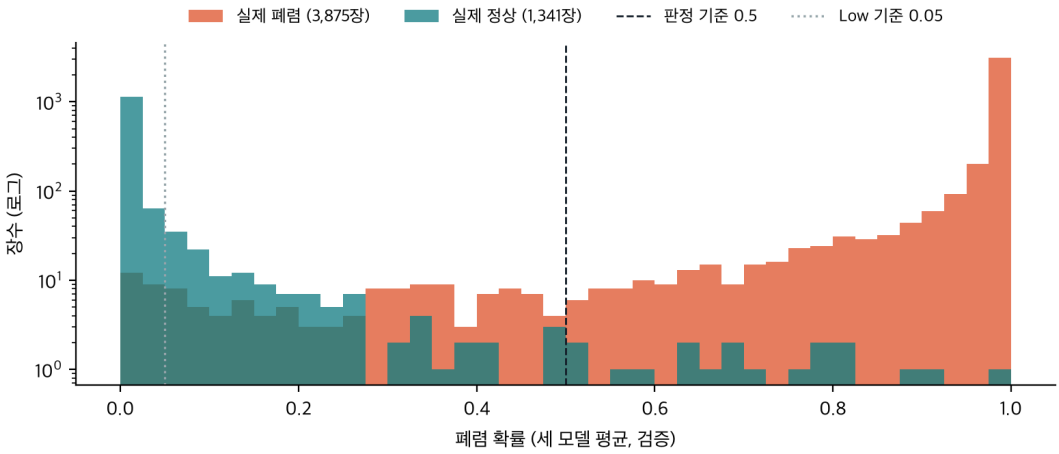


그림 6. 최종 모델의 폐렴 확률 분포(세로축 로그). 87%가 0.05 이하 또는 0.95 이상에 몰려 있고, 애매한 구간에는 실제 폐렴이 많음

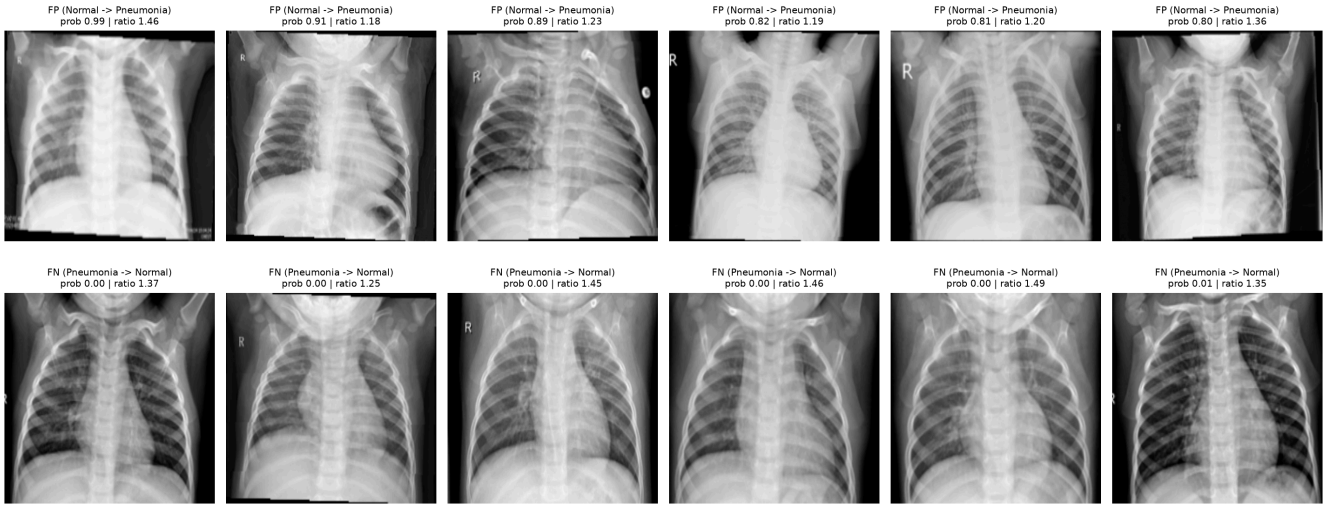


그림 7. 가장 확신하며 틀린 사진. 윗줄은 정상을 폐렴으로, 아랫줄은 폐렴을 정상으로 본 경우

- **대부분 폐렴을 놓친 경우:** 틀린 144장 중 126장(88%)
- **애매해서 틀린 사진이 많음:** 확신도(기준 0.5에서 떨어진 거리) 평균이 맞힌 사진 0.476, 틀린 사진 0.253. 놓친 폐렴 중 55장은 확률 0.3~0.5였음
- **확신하며 놓친 폐렴도 있음:** 34장은 확률 0.1 미만. 그림으로 보면 폐가 검고 선명해 정상과 구분이 잘 안 되고, 사진 가장자리나 모서리가 검게 남아 있음 (눈으로 본 인상이고 의학적 판단은 아님)
- **정상을 폐렴으로 본 사진은 사진 상태가 달랐음:** 6장 중 2~3장은 살짝 돌아가 모서리에 검은 삼각형이 보이고, 2장은 전체가 밝고 대비가 낮아 폐가 뿌옇게 보임
- **사진 모양의 영향이 조금 남음:** 틀린 정상은 비율 1.26(맞힌 정상 1.18), 틀린 폐렴은 1.35(맞힌 폐렴 1.45)

8 모델 해석 (Grad-CAM)

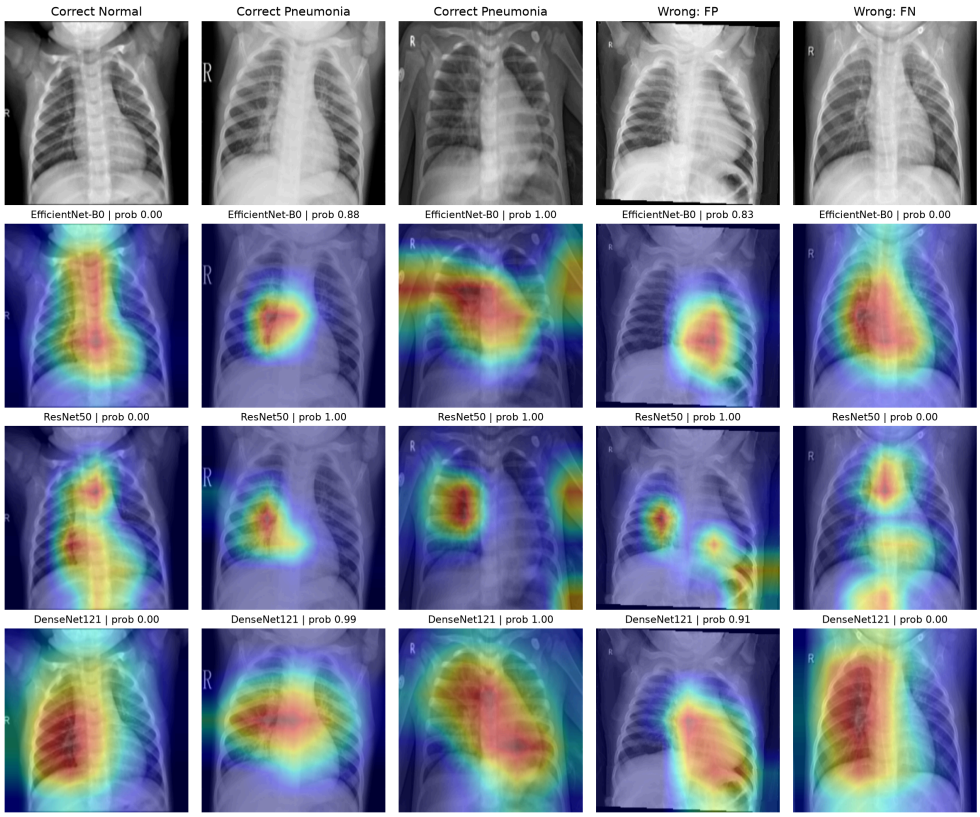


그림 8. 학습 때 보지 못한 사진(fold 1 검증)에서 세 모델의 Grad-CAM. 위에서부터 원본, EfficientNet-B0, ResNet50, DenseNet121. 빨간색일수록 판단에 많이 쓴 부분

- **가장자리가 아니라 가슴 가운데를 봄:** 가운데 70%×70% 영역(면적 50%)에 히트맵의 86% / 73% / 71%(위 순서)가 몰려 있음 (200장 기준). 구석의 글자 표시나 테두리를 보고 판단하지는 않음
- **보는 방식이 서로 다름:** EfficientNet-B0은 큰 덩어리 하나, ResNet50은 작은 점 여러 개, DenseNet121은 폐 영역 전체에 넓게 나타남. 세 모델의 상관이 낮고 평균이 효과가 있었던 것과 맞음
- **병변을 정확히 본다고는 말할 수 없음:** 정상 사진에서도 히트맵은 심장·척추 부근에 있는 경우가 많았고, 틀린 사진이라고 위치가 눈에 띄게 다르지 않았음. Grad-CAM은 7×7 지도를 키운 것이라 위치가 대략적임

그래서 Grad-CAM은 "엉뚱한 곳(테두리, 글자)을 보지 않는다"는 확인 용도로 쓰고, 진단 근거로 그대로 보여주지 않는 것이 맞다고 판단함.

9 서비스로 만든다면

9.1 위험도 3단계

최종 모델의 약점이 폐렴을 놓치는 것이므로, 판정 하나 대신 위험도로 내보내고 놓친 환자가 **의사 확인 단계**에 들어가도록 기준을 정함.

위험도	폐렴 확률	실제 정상	실제 폐렴	의미
Low	0.05 미만	1,194	21	우선순위 낮음 (정상 확정 아님)
Medium	**0.05 ~ 0.5**	**129**	**105**	**의사 확인 필요**
High	0.5 이상	18	3,749	빠른 확인 필요

- 놓친 폐렴 126장 중 **105장이 Medium**에 들어감. 의사가 볼 Medium은 전체의 4.5%(234장)임
- 기준을 0.02로 낮춰도 Low에 폐렴 10장이 남고 Medium은 6.4%로 늘어남. 0.15로 올리면 Low 속 폐렴이 44장으로 늘어남
- Low에도 폐렴이 남으므로 화면에는 "정상"이 아니라 "우선순위 낮음"으로 표시해야 함
- 기준은 폐렴이 74%인 train으로 정한 것이라, 실제 병원의 환자 비율에서는 다시 정해야 함

9.2 저장할 결과 데이터

항목	의미
원본 이미지	다시 확인하거나 재학습할 때 필요
Grad-CAM 이미지	모델이 엉뚱한 곳을 보지 않았는지 확인 (ResNet50 fold 1 모델로 생성)
예측 결과 / 확률	정상·폐렴 판정과 폐렴 확률. 같은 폐렴이어도 0.55와 0.99는 다름
위험도	Low / Medium / High. 의사가 볼 순서를 정할 때 사용
모델 버전 / 예측 시간	모델이 바뀌어도 예전 결과를 추적할 수 있게 함

10 배운 점

1. **모델보다 데이터를 먼저 봐야 함.** 모델과 앙상블을 바꿔 0.85 → 0.92로 올리는 데 여러 날이 걸렸는데, 검은 띠를 찾은 뒤에는 모델 하나로 0.9471이 나옴
2. **높은 검증 점수일수록 이유를 물어야 함.** 무작위 분할의 0.9875도, Baseline의 0.9425도 실제 실력이 아니었음
3. **지름길을 확인하는 숫자를 만들어야 함.** "가로로 긴 정상 사진의 정확도" 하나로 모델이 띠를 보는지 폐를 보는지 구분할 수 있었음 (0.457 vs 0.952)
4. **앙상블은 수보다 서로 얼마나 다른지가 중요함.** 비슷한 모델을 더하면 내려갔고, 단서를 배운 모델이 섞이면 장점이 희석됐음
5. **검증에도 한계가 있고, 그때는 멈추는 것도 선택임.** 후반에는 검증이 올라도 제출이 내려갔음. 리더보드에 맞추는 대신 원칙을 지키고 멈췄음
6. **정확도만으로는 의료 모델을 설명할 수 없음.** 최종 모델은 폐렴을 놓치는 쪽으로 틀리므로, 위험도로 내보내 사람이 확인하게 해야 함

11 한계와 다음 과제

- **train과 test의 차이가 끝까지 남음.** 검증이 오른 변경이 test에서 내려간 이유를 정답 없이는 확인할 수 없었음
- **검증 점수가 실제보다 조금 높게 나옴.** fold마다 검증 정확도가 가장 높은 에포크를 골랐는데, 에포크마다 점수가 크게 흔들려 운 좋은 에포크가 뽑히는 효과가 있음
- **다른 사진 모양 단서가 남아 있을 수 있음.** 놓친 폐렴 126장 중 117장이 내용 영역의 모서리가 검은 사진이었고, train에서 모서리가 검지 않은 사진은 93%가 폐렴임
- **환자 묶음은 근사임.** 환자 ID가 없어 연속 10장을 한 환자로 가정했음

- **Grad-CAM으로 병변을 본다는 것은 확인하지 못함.** 병변 위치 라벨이 있는 데이터로 검증이 필요함
- **해보지 못한 것:** 입력 크기를 키우는 실험(320×320), 위험도 기준을 실제 환자 비율에서 다시 정하는 것

부록 제출물과 관련 파일

파일	내용
`xray_pneumonia.ipynb`	최종 코드. 데이터 확인 → 전처리 → 세 모델 5-fold 학습 → 검증 → 제출 파일 → 분석 (Baseline 비교, 틀린 사진, Grad-CAM, 위험도, 결과 데이터)
`submission_3models.csv`	최종 제출 파일 (0.9583). 최종 코드가 만드는 `submission.csv`와 624장이 같음
`submission_baseline.csv`	Baseline 제출 파일 (0.7804)
`모델이름_fold번호.npz`	fold별 검증 확률과 test 확률. 다시 실행하면 끝난 fold는 건너뜀
`results/`	서비스용 결과 데이터 예시와 Grad-CAM 이미지

작업 환경: MacBook (Apple Silicon, mps), Python 3, PyTorch, torchvision, scikit-learn · 포트폴리오: github.com/elin-115/portfolio