AI 헬스케어 해커톤 최종 보고서

# 흉부 X-ray 폐렴 분류

## 모델을 바꾸기 전에 데이터를 먼저 봐야 했던 이유

김지연 | OZ코딩스쿨 AI 헬스케어 7기

# 문제 정의

흉부 X-ray 사진을 정상(0) / 폐렴(1)로 분류 · 평가 산식 Accuracy

**5,216장**

**train**

정상 1,341 / 폐렴 3,875
전부 224×224, 검은 띠 포함

**624장**

**test**

정답 없음, 원본 크기 그대로
예측에만 사용 (학습·통계에 쓰면 누수)

**0.9583**

**최종 제출 점수**

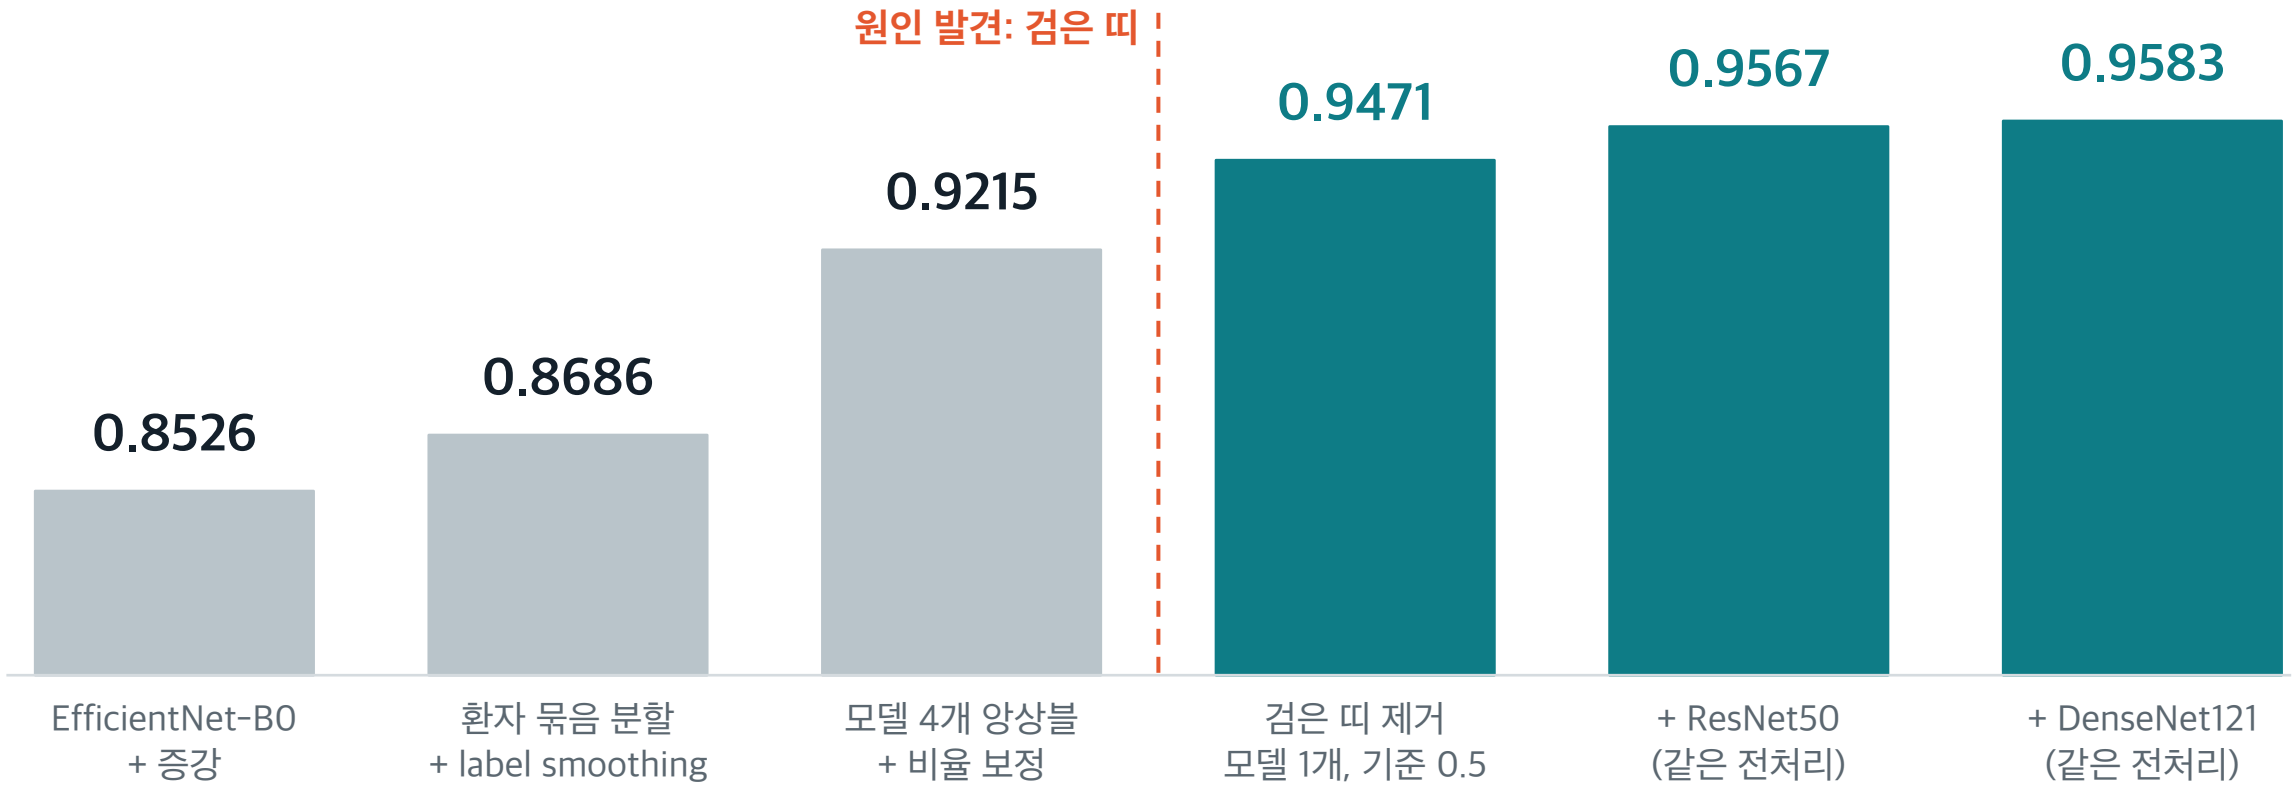
Baseline 검증 0.9425에서 출발
624장 중 598장 정답

**처음에는 "좋은 모델을 고르는 문제"라고 생각함**

실제로는 train과 test의 사진 모양이 다른 것이 핵심이었고, 모델보다 전처리가 점수를 결정했음

# 점수는 원인을 찾은 뒤에 올랐음

제출 점수 흐름 (test 624장 Accuracy)

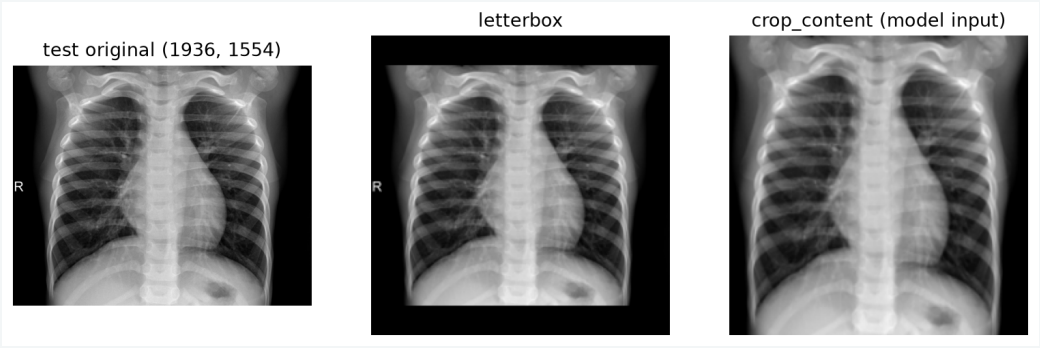



앞의 세 단계는 원인을 모른 채 모델과 앙상블로 올린 점수임. 세 번째의 비율 보정은 test 예측 분포에 의존하는 방식이라 최종 모델에서는 쓰지 않음

# 발견 1·2: 사진 형태 차이와 환자 누수

## train과 test의 형태가 다름

- train: 비율을 유지한 채 224×224에 넣고 남는 곳을 검게 채운 형태
- test: 원본 크기 그대로 (사진마다 다름)
- test도 같은 방식으로 맞춘 뒤 처리함




## 검증 점수가 부풀려지는 구조

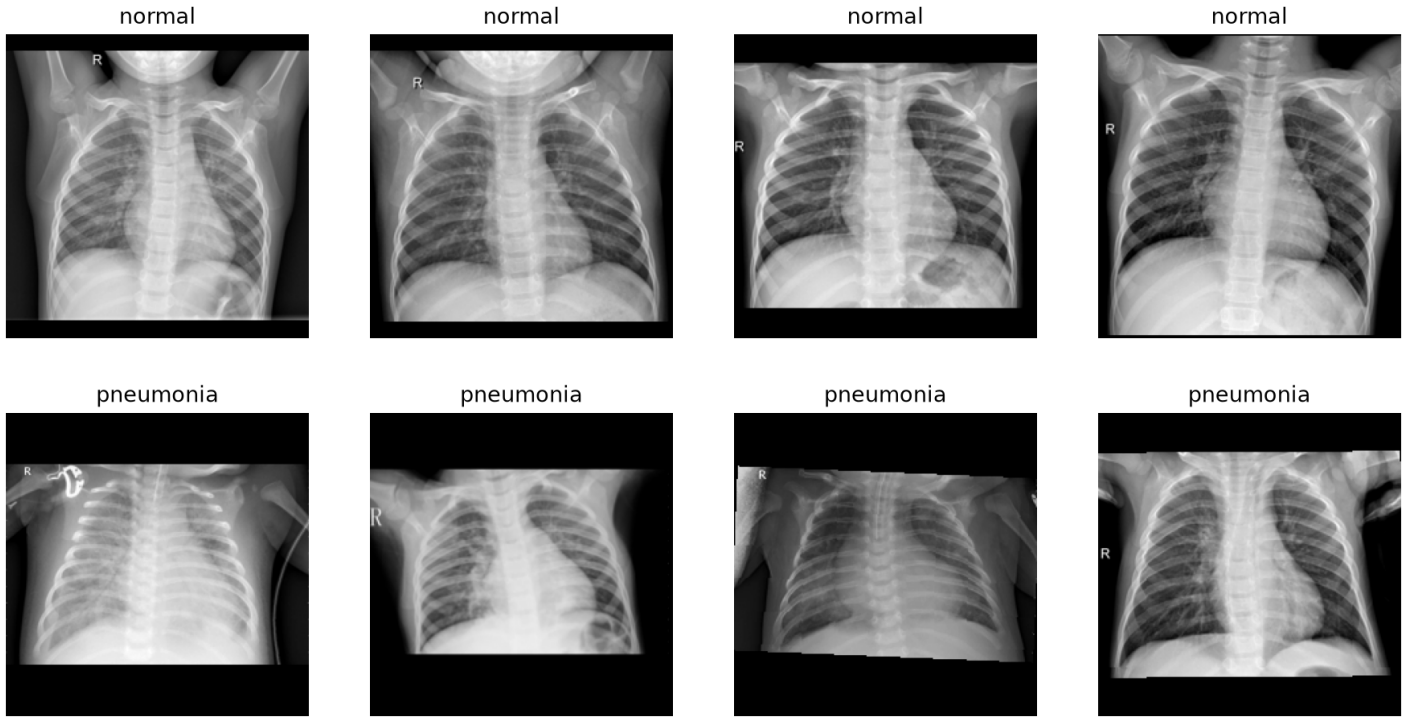
- 파일 번호가 환자 순서 → 옆 번호는 같은 환자인 경우가 많음
- 무작위로 나누면 검증 사진의 94%가 옆 번호를 학습에 둠
- 연속 10장을 한 묶음으로 보고 묶음 단위 5-fold로 변경

**0.9875** → **0.8526**

무작위 분할 검증 | 실제 제출 점수

# 발견 3: 검은 띠가 정답을 알려주고 있었음

폐렴 사진이 가로로 더 길어서 위아래 검은 띠가 더 두꺼움




윗줄 정상, 아랫줄 폐렴 (train 원본)

**1.18 vs 1.44**

내용 부분의 가로÷세로 (정상 vs 폐렴)

**AUC 0.88**

이 비율 하나만으로 구분되는 정도

**99.5%**

비율 1.5 초과 train 사진 중 폐렴

**모델이 폐를 보지 않고 띠의 두께만 봐도 train에서는 잘 맞힘. test에는 가로로 긴 정상 사진이 많아서 그대로 틀림**

# 전략 선택

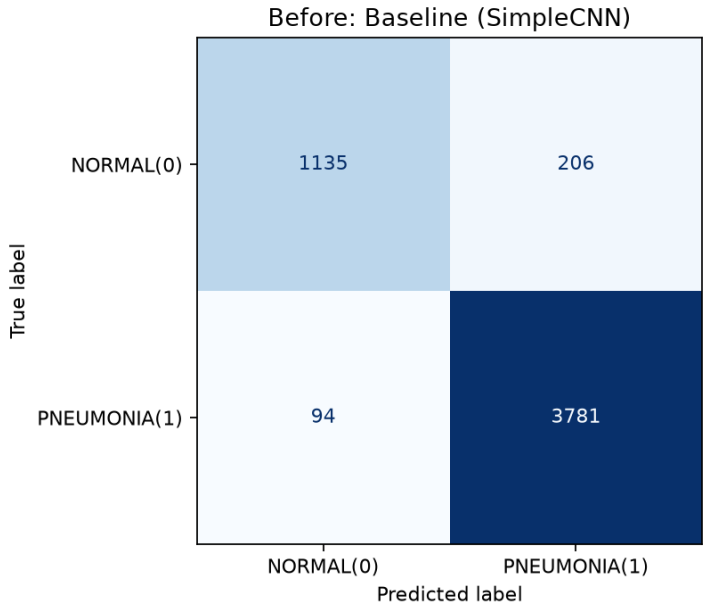
발견한 문제마다 하나씩 대응함

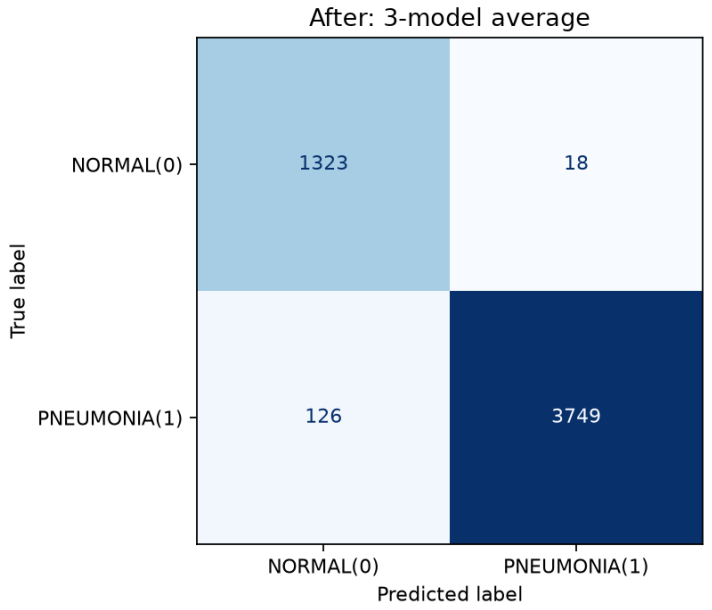
| 문제 | 선택한 전략 | 이유 |
| --- | --- | --- |
| **검은 띠 단서** | 검은 띠를 잘라내고 224×224에 꽉 채움 | 띠의 두께 정보를 없앰 |
| **사진 비율 단서** | 학습 때 가로세로 비율을 무작위로 흔듦 | 늘어난 정도로도 맞히지 못하게 함 |
| **환자 누수** | 10장 묶음 단위 5-fold | 검증 점수를 믿을 수 있게 함 |
| **폐렴이 3배 많음** | 클래스 가중치 | 정상을 틀리면 더 큰 벌점 |
| **모델 하나의 흔들림** | 5-fold 평균 + 서로 다른 모델 3개 평균 | 에포크마다 검증 점수가 크게 변함 |
| **판정 기준** | 0.5 고정, 비율 보정 없음 | test를 보고 기준을 정하지 않음 |

모델: ImageNet 사전학습 EfficientNet-B0, ResNet50, DenseNet121

# Before vs After: Baseline과 비교

같은 5-fold로 train 5,216장 전체를 검증한 결과




| | Baseline | 최종 모델 |
|---|---|---|
| 검증 정확도 | 0.9425 | **0.9724** |
| AUC | 0.9819 | **0.9971** |
| 민감도 | 0.9757 | **0.9675** |
| 특이도 | 0.8464 | **0.9866** |
| FP / FN | 206 / 94 | **18 / 126** |
| 제출 점수 | 0.7804 | **0.9583** |

**가로로 긴 정상 사진의 정확도**

**0.457 → 0.952**

Baseline은 정확도가 0.94여도 이 사진은 절반도 못 맞힘 → 폐가 아니라 띠로 판단한다는 증거임.
다만 최종 모델은 폐렴을 놓치는 쪽(FN 126장)이 약점으로 남음

# 효과가 없었던 시도

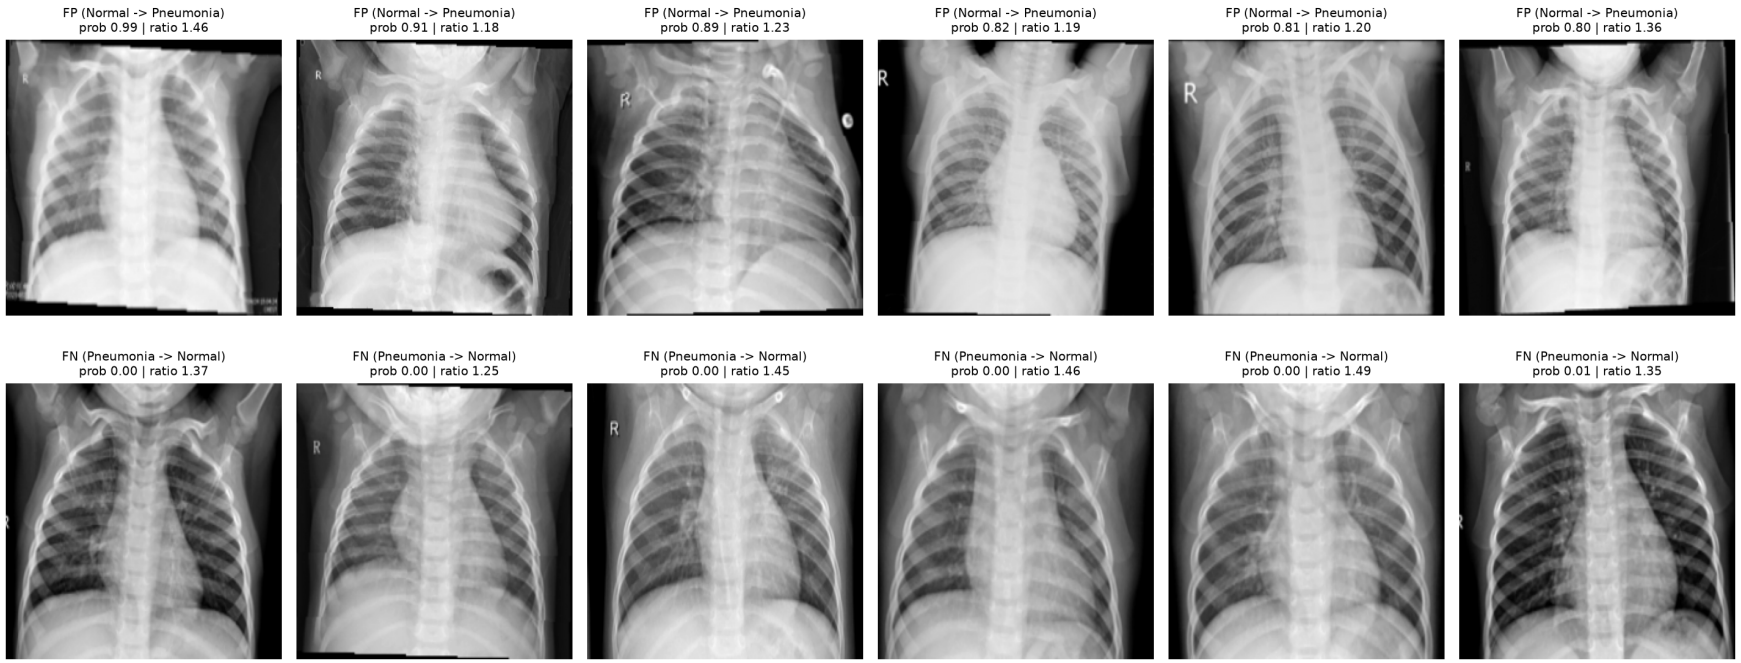
검증 점수가 올라도 제출 점수는 오르지 않았음

| 시도 | 기대한 근거 | 제출 결과 |
|---|---|---|
| **판정 기준을 0.5 → 0.3으로 낮춤** | 검증에서 폐렴을 많이 놓쳐서 | **0.9487 → 0.9439** |
| **흉부 X-ray로 사전학습된 모델** | 의료 영상으로 배운 모델이 나을 것 | **평균해도 +1장** |
| **폐 영역만 잘라서 학습 (두 모델 평균에 추가)** | 검증 0.9695 → 0.9770으로 상승 | **0.9567 → 0.9487** |
| **시드만 바꿔 다시 학습** | 평균하면 안정될 것 | **624장 예측 동일** |
| **띠 단서를 배운 예전 모델과 앙상블** | 모델이 많을수록 좋을 것 | **오히려 하락** |

**폐렴 쪽으로 판정을 옮긴 변경(기준 0.3, 폐 영역 자르기)은 두 번 모두 내려감 → 검증만 보고 정하면 안 된다는 신호**

# 최종 모델이 틀린 사진

검증 5,216장 중 144장 · 윗줄 정상→폐렴, 아랫줄 폐렴→정상 (가장 확신하며 틀린 6장씩)




**126 / 144**

틀린 사진 중 폐렴을 놓친 경우 (88%)

**0.476 vs 0.253**

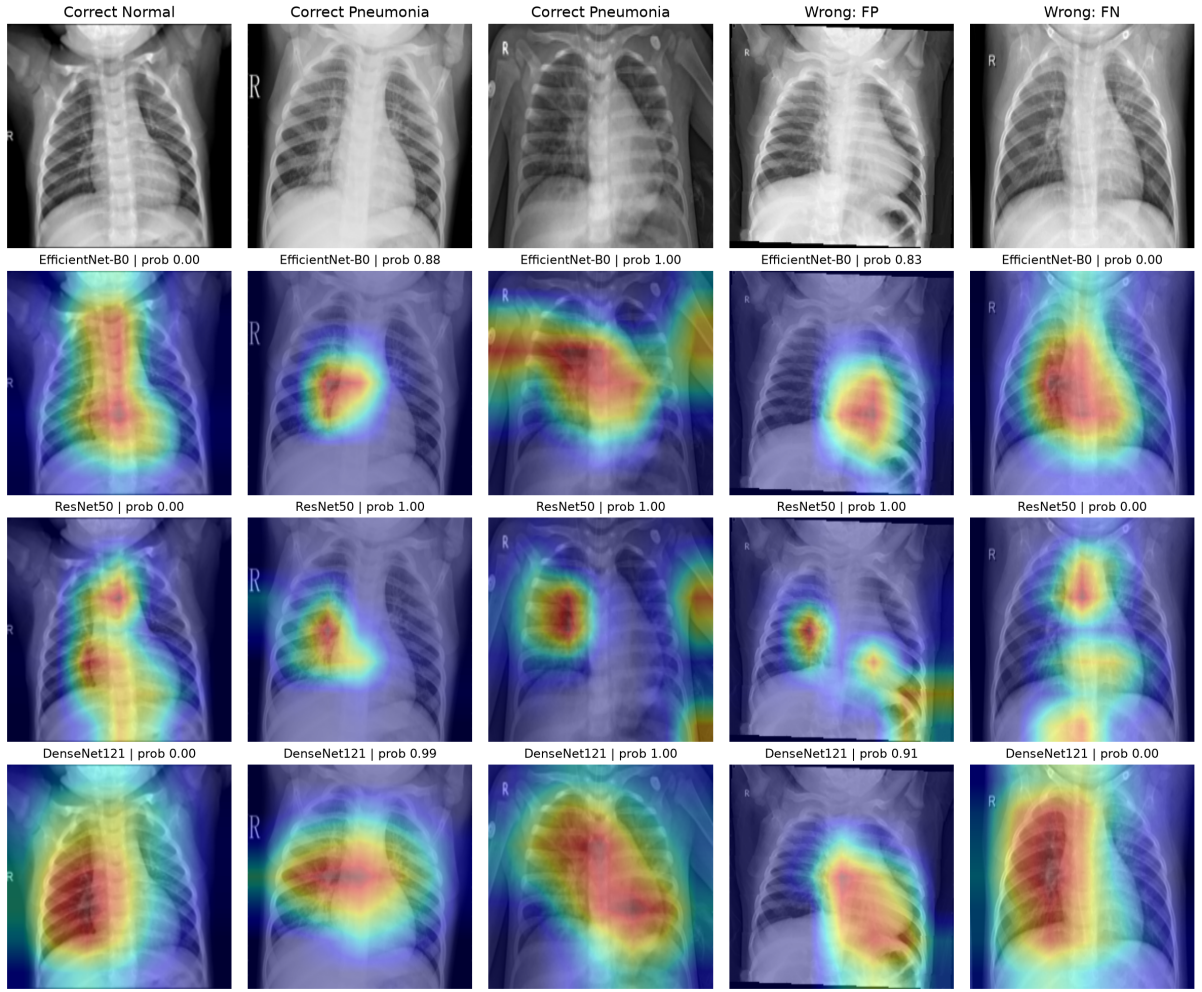
확신도 평균: 맞힌 사진 vs 틀린 사진

**34장**

확률 0.1 미만으로 확신하며 놓친 폐렴

# 모델 해석: Grad-CAM

학습 때 보지 못한 사진에서 세 모델이 어디를 보는지 비교




## 86 / 73 / 71%

히트맵 중 가슴 가운데 영역 비중
(위에서부터 세 모델, 면적은 50%)

## 상관 0.80~0.88

세 모델이 보는 방식이 다름
→ 평균내는 효과가 있는 이유

### 한계

테두리나 글자를 보지 않는다는 것까지만 확인됨. 폐의 병변을 정확히 본다고는 말할 수 없음

# 서비스 관점: 위험도 3단계

판정 결과 하나가 아니라 Low / Medium / High로 내보냄

| 위험도 | 폐렴 확률 | 실제 정상 | 실제 폐렴 | 의미 |
|---|---|---|---|---|
| Low | 0.05 미만 | 1,194 | **21** | 우선순위 낮음 |
| Medium | 0.05 ~ 0.5 | 129 | **105** | 의사 확인 필요 |
| High | 0.5 이상 | 18 | **3,749** | 빠른 확인 필요 |

**105 / 126**

놓친 폐렴 중 Medium에 들어가 의사 확인을 거치는 수

**4.5%**

의사가 볼 Medium

- Low에도 폐렴 21장이 남음 → Low는 "정상 확정"이 아니라 "우선순위 낮음"으로 표시해야 함
- 기준은 폐렴이 74%인 train으로 정함 → 실제 병원 비율에서는 다시 정해야 함
- 저장 항목: 원본 이미지, Grad-CAM 이미지, 예측 결과, 확률, 위험도, 모델 버전, 예측 시간

# 최종 인사이트

1

## 모델보다 데이터를 먼저 봐야 함

앙상블로 0.85 → 0.92까지 여러 날, 검은 띠를 찾은 뒤에는 모델 하나로 0.9471

2

## 높은 검증 점수를 의심해야 함

무작위 분할 0.9875도, Baseline 0.9425도 실제 실력이 아니었음

3

## 지름길을 확인하는 숫자를 만들어야 함

"가로로 긴 정상 사진의 정확도" 하나로 띠를 보는지 구분함 (0.457 vs 0.952)

4

## 검증에도 한계가 있음

후반에는 검증이 올라도 제출이 내려감. 반복 제출로 맞추지 않고 멈춤

5

## 정확도만으로는 의료 모델을 설명할 수 없음

폐렴을 놓치는 쪽으로 틀리므로 위험도 3단계로 내보내야 함

# 한계와 다음에 해볼 것

- train과 test의 분포 차이가 끝까지 남음. 정답 없이는 원인을 확인할 수 없었음
- Grad-CAM으로 병변을 본다는 것을 확인하지 못함. 병변 위치 라벨이 있는 데이터가 필요함
- 위험도 기준은 train 비율로 정함. 실제 환자 비율에서 다시 정해야 함
- 검증 점수가 실제보다 조금 높게 나옴. 검증 정확도가 가장 높은 에포크를 골랐기 때문
- 검은 띠 말고 검은 모서리 단서도 남아 있을 수 있음. 놓친 폐렴 126장 중 117장이 모서리가 검은 사진
- 입력 크기를 키우는 실험(320×320)은 해보지 못함

최종 코드 xray_pneumonia.ipynb | 최종 제출 submission.csv (0.9583)